

Likelihood bei der linearen Regression

Warum Least Squares und Maximum Likelihood dasselbe sind

Die Idee

Eine Regressionsgerade $\hat{y} = mx + b$ durch eine Punktwolke zu legen, ist im Grunde ein Likelihood-Problem. Jede mögliche Gerade erzeugt andere **Residuen** – die vertikalen Abstände zwischen Datenpunkten und Geraden: $r_i = y_i - \hat{y}_i = y_i - (mx_i + b)$.

Man nimmt an, dass die Residuen **normalverteilt** sind: $r_i \sim \mathcal{N}(0, \sigma)$. Die *beste* Gerade ist diejenige, bei der die Residuen die **höchste Likelihood** haben – also möglichst klein und symmetrisch um Null verteilt sind:

$$\mathcal{L}(m, b \mid \text{Daten}) = \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{r_i^2}{2\sigma^2}\right)$$

Wichtig: Der konkrete Wert von σ spielt dabei keine Rolle – man kann zeigen, dass er das Ergebnis der Optimierung nicht beeinflusst. Egal wie groß oder klein σ ist, die *beste* Gerade bleibt dieselbe.

Das Maximieren der Likelihood ist damit gleichbedeutend mit dem **Minimieren der Summe der quadrierten Residuen** – also genau das, was die Methode der kleinsten Quadrate (Least Squares) tut:

$$\text{Minimiere } \sum_{i=1}^n r_i^2 = \sum_{i=1}^n (y_i - (mx_i + b))^2$$

Beispiel: Eine schlecht gewählte Gerade




Abbildung 1: **Links:** Schlecht gewählte Gerade ($y = 0,7x + 8$), gestrichelte Linien zeigen die Residuen. **Rechts:** Die Residuen als Histogramm – ihr Mittelwert liegt deutlich von Null entfernt. Auf einer $\mathcal{N}(0, \sigma)$ hätten sie eine *niedrige* Likelihood.

Die optimale Gerade (= Maximum-Likelihood-Lösung) würde die Residuen so verschieben, dass ihr Mittelwert bei Null liegt und ihre Streuung minimal ist.

Zusammengefasst: Wenn man eine Regressionsgerade mit *Least Squares* fittet, macht man implizit eine Maximum-Likelihood-Schätzung – unter der Annahme, dass die Residuen normalverteilt sind. Likelihood ist also nicht nur ein abstraktes Konzept, sondern steckt hinter vielen alltäglichen ML-Methoden.